

DC-02 MAP REDUCE

DC-02 TRABAJO PRÁCTICO 01 MAP REDUCE

Programa: Máster Executive en Big Data, Cloud &

Analytics

Periodo académico: 2019-2020

Autor/es: CARLOS ALFONSEL JAÉN



OBJETIVO DEL TRABAJO PRÁCTICO:

- Recordar y fijar los conceptos vistos en las sesiones de clase sobre Hadoop HDFS y Map
 Reduce.
- Evaluar un 25% de la nota final del sub-módulo.

DESCRIPCIÓN:

- Debemos obtener un repositorio de términos para poder traducir a diferentes idiomas.
- Disponemos de unos diccionarios de inglés a diferentes idiomas.
- Cada fichero contiene términos y su traducción a un determinado idioma, separados por un tabulador.
- Para evitar complejidad: no nos importa si todos los términos figuran en todos los idiomas. Tampoco si un término tiene varias acepciones en un mismo idioma.
- Entregar en un PDF los pasos, comandos y los pantallazos del proceso realizado contra el clúster de Dataproc de Google Cloud.

SE PIDE:

- Descargar los ficheros de idiomas de la web.
 Usar el comando (wget http://www.ilovelanguages.com/IDP/files/German.txt, etc.)
- 2. Subir a HDFS.

Ya sabemos que Hadoop está especialmente diseñado para trabajar con ficheros muy grandes. Por ese motivo vamos a agregar los ficheros de forma que generaremos un fichero dictionary.txt con el contenido de cada uno de los ficheros individuales descargados (usar el comando cat [nombre fichero] >> dictionary.txt)

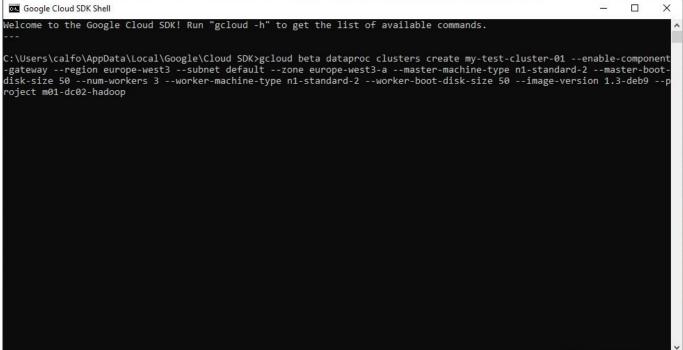
- 3. Ejecutar los procesos Map Reduce que hay en los scripts de Python adjuntos. Se pueden sugerir mejoras al código actual.
- 4. Mostrar el resultado del término "House".

RESPUESTAS:

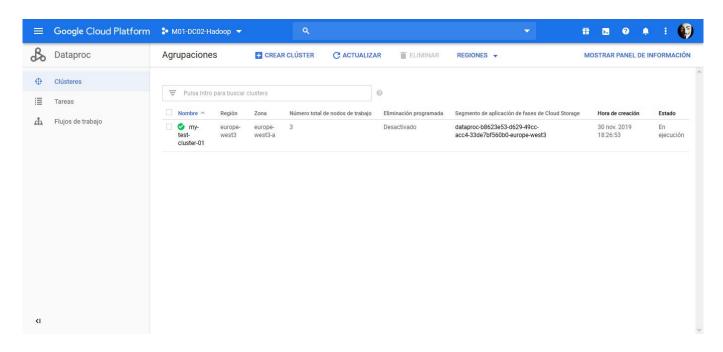
- 1. El primer paso es crear un clúster en Google Cloud Platform (GCP):
 - a. Desde la Google Cloud SDK Shell:

```
> gcloud beta dataproc clusters create my-test-cluster-01 --
enable-component-gateway --region Europe-west3 --subnet default
--zone Europe-west3-a --master-machine-type n1-standard-2 --
master-boot-disk-size 50 --num-workers 3 --worker-machine-type
n1-standard-2 --worker-boot-disk-size 50 --image-version 1.3-
deb9 --project m01-dc02-hadoop
```



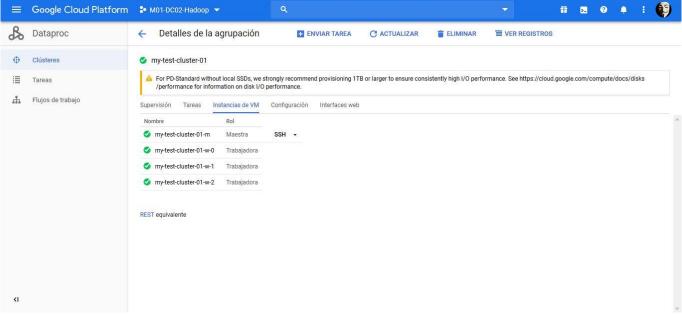


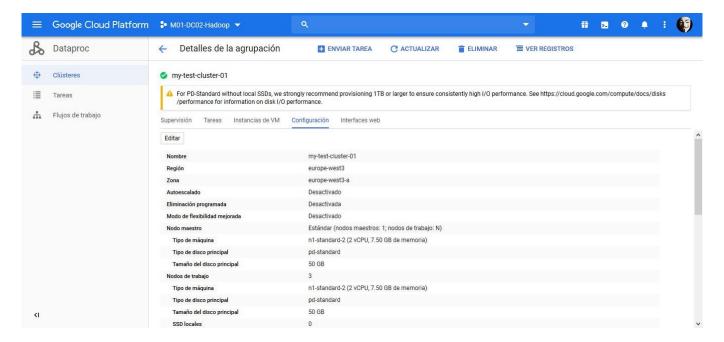
b. Comprobamos en GCP que el clúster ha arrancado correctamente:



c. El clúster consta de un nodo maestro y tres trabajadores, todos de tipo n1-standard-2 (2 vCPU y 7.5 GB de memoria cada uno) y 50 GB de espacio en disco.



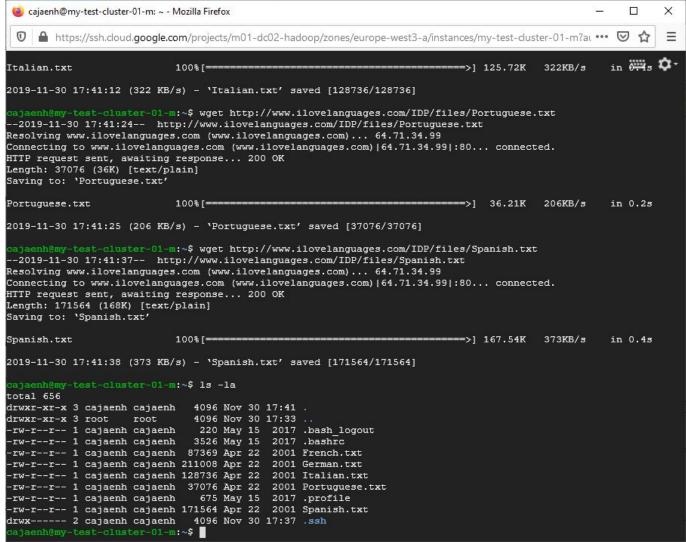




 A continuación, desde la consola del clúster importamos los 6 diccionarios que vamos a utilizar para la práctica (francés, alemán, italiano, latín, portugués y español), ejecutando los siguientes comandos:

```
$ wget http://www.ilovelanguages.com/IDP/files/French.txt
$ wget http://www.ilovelanguages.com/IDP/files/German.txt
$ wget http://www.ilovelanguages.com/IDP/files/Italian.txt
$ wget http://www.ilovelanguages.com/IDP/files/Latin.txt
$ wget http://www.ilovelanguages.com/IDP/files/Portuguese.txt
$ wget http://www.ilovelanguages.com/IDP/files/Spanish.txt
```





Y antes de subirlos a HDFS los combinamos en un único fichero **dictionary.txt** que además se ordena alfabéticamente:

```
$ cat French.txt German.txt Italian.txt Latin.txt Portuguese.txt
Spanish.txt | sort > dictionary.txt
```

Para poder practicar más tarde con un fichero que supere el tamaño mínimo de bloque (1048576 bytes), y al no haber más diccionarios disponibles, concateno dos veces el archivo existente y lo llamo **dictionaryx2.txt**.

\$ cat dictionary.txt dictionary.txt > dictionaryx2.txt



```
  cajaenh@my-test-cluster-01-m: ~ - Mozilla Firefox

                                                                                                                                                                                          X
  🔻 🖴 https://ssh.cloud.google.com/projects/m01-dc02-hadoop/zones/europe-west3-a/instances/my-test-cluster-01-m?at 🚥 💆 🏠
                                                                                                                                                                                - D
  ajaenh@my-test-cluster-01-m:-$ wget http://www.ilovelanguages.com/IDP/files/Spanish.txt-
-2019-11-30 17:41:37-- http://www.ilovelanguages.com/IDP/files/Spanish.txt
Resolving www.ilovelanguages.com (www.ilovelanguages.com) ... 64.71.34.99

Connecting to www.ilovelanguages.com (www.ilovelanguages.com) | 64.71.34.99 | :80... connected.

HTTP request sent, awaiting response... 200 OK

Length: 171564 (168K) [text/plain]

Saving to: 'Spanish.txt'
                                               100%[==
                                                                                                                              ==>] 167.54K 373KB/s
                                                                                                                                                                          in 0.4s
2019-11-30 17:41:38 (373 KB/s) - `Spanish.txt' saved [171564/171564]
total 656
drwxr-xr-x 3 cajaenh cajaenh 4096 Nov 30 17:41 .
                                   root
                                                   4096 Nov 30 17:33 ..
220 May 15 2017 .bash_logout
3526 May 15 2017 .bashrc
drwxr-xr-x 3 root
 -rw-r--r-- 1 cajaenh cajaenh
 rw-r--r-- 1 cajaenh cajaenh
 -rw-r--r-- 1 cajaenh cajaenh 87369 Apr 22 2001 French.txt
-rw-r--r-- 1 cajaenh cajaenh 211008 Apr 22 2001 German.txt
 rw-r--r-- 1 cajaenh cajaenh 128736 Apr 22
                                                                          2001 Italian.txt
 -rw-r--r-- 1 cajaenh cajaenh 37076 Apr 22 2001 Portuguese.txt
-rw-r--r-- 1 cajaenh cajaenh 675 May 15 2017 .profile
-rw-r--r-- 1 cajaenh cajaenh 171564 Apr 22 2001 Spanish.txt
drwx----- 2 cajaenh cajaenh
                                                   4096 Nov 30 17:37 .ssh
        enhêmy-test-cluster-01-m:~$ cat French.txt German.txt Italian.txt Portuguese.txt Spanish.txt | sort > joinDi
ctio.txt
                 -test-cluster-01-m:~$ 1s -la
total 1280
drwxr-xr-x 3 cajaenh cajaenh 4096 Nov 30 17:44
drwxr-xr-x 3 root
                                                   4096 Nov 30 17:33
 rw-r--r- 1 cajaenh cajaenh 220 May 15 2017 .bash_logout
rw-r--r- 1 cajaenh cajaenh 3526 May 15 2017 .bashrc
rw-r--r- 1 cajaenh cajaenh 87369 Apr 22 2001 French.txt
rw-r--r- 1 cajaenh cajaenh 211008 Apr 22 2001 German.txt
rw-r--r- 1 cajaenh cajaenh 128736 Apr 22 2001 Italian.txt
rw-r--r- 1 cajaenh cajaenh 635753 Nov 30 17:44 joinDictio.txt
 rw-r--r- 1 cajaenh cajaenh
-rw-r--r- 1 cajaenh cajaenh
-rw-r--r- 1 cajaenh cajaenh
                                                     220 May 15 2017 .bash_logout
 -rw-r--r-- 1 cajaenh cajaenh 37076 Apr 22 2001 Portuguese.txt
-rw-r--r-- 1 cajaenh cajaenh 675 May 15 2017 .profile
-rw-r--r-- 1 cajaenh cajaenh 171564 Apr 22 2001 Spanish.txt
                           aenh cajaenh 4096 Nov 30 17:37
drwx----- 2 cajaenh cajaenh
   ijaenh@my-test
```

3. Editamos los scripts de Python mapper.py y reducer.py utilizando el comando nano:

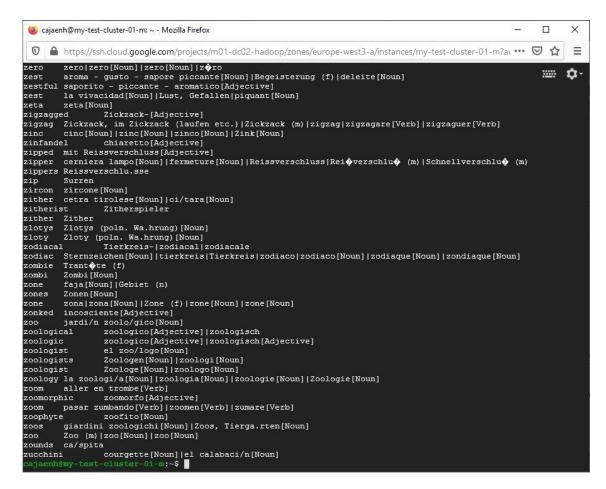
```
$ nano mapper.py
$ nano reducer.py
```

```
in in the properties of the p
```



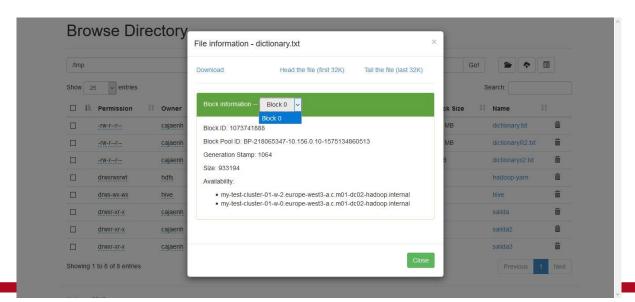
Se prueba en local que los procesos Map Reduce funcionan correctamente:

\$ cat dictionary.txt | python mapper.py | sort | python reducer.py



4. Subimos los diccionarios a HDFS con el comando hadoop fs -put:

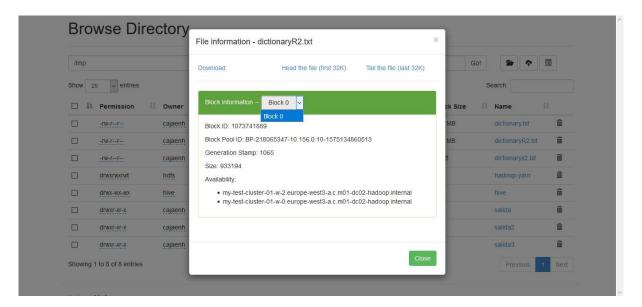
\$ hadoop fs -put dictionary.txt /tmp/dictionary.txt





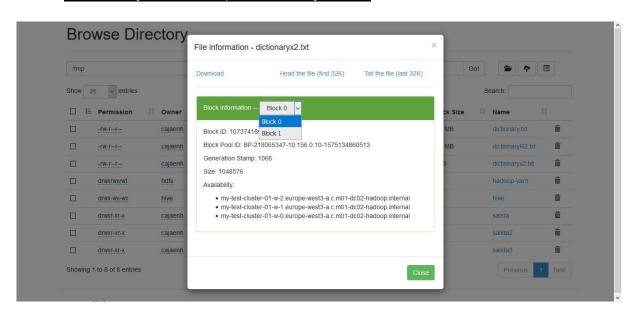
Con factor de replicación 2:

\$ hadoop fs -D dfs.replication=2 -put dictionary.txt /tmp/dictionaryR2.txt



Con factor de replicación 3 y tamaño de bloque 1048576:

\$ hadoop fs -D dfs.replication=3 -D dfs.block.size=1048576 -put dictionaryx2.txt /tmp/dictionaryx2.txt



5. Aplicamos la función Map Reduce a los tres diccionarios alojados en el HDFS del clúster:

\$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming.jar ackslash

- -D mapred.reduce.tasks=1 \
- > -files mapper.py,reducer.py \
- > -mapper mapper.py \



- > -reducer reducer.py \
- -input /tmp/dictionary.txt \
- -output /tmp/salida

```
$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming.jar \
  -D mapred.reduce.tasks=1 \
 -files mapper.py,reducer.py \
 -mapper mapper.py \
 -reducer reducer.py \
> -input /tmp/dictionaryR2.txt \
```

> -output /tmp/salida2

```
\$ hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming.jar ackslash
 -D mapred.reduce.tasks=1 \
 -files mapper.py,reducer.py \
 -mapper mapper.py \
 -reducer reducer.py \
 -input /tmp/dictionaryx2.txt \
 -output /tmp/salida3
```

```
đ
🚳 cajaenh@my-test-cluster-01-m: ~ - Mozilla Firefox
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  ... ☑ ☆ ≡
   🕡 🖴 https://ssh.doud.google.com/projects/m01-dc02-hadoop/zones/europe-west3-a/instances/my-test-duster-01-m?authuser=0&hl=es&projectNumber=439175557931
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      - Q-
                                                                                                                            10 Nov 30 19:26 .
5 Nov 30 19:26 .
5 Nov 30 17:33 ...
5 Nov 30 17:33 ...
6 May 15 2017 .bash logout
6 May 15 2017 .bashrc
1 Nov 30 19:05 dictionary.txt
1 Apr 22 2001 French.txt
1 Apr 22 2001 French.txt
1 Apr 22 2001 German.txt
2 Nov 30 19:26 house2.txt
5 Nov 30 19:26 house3.txt
6 Apr 22 2001 Lalian.txt
1 Apr 22 2001 Lalian.txt
1 Apr 22 2001 Latin.txt
1 Nov 30 19:26 mapper.py
1 Nov 30 17:47 .mano
2 Apr 22 2001 Fortuguese.txt
5 May 15 2017 .profile
8 Nov 30 18:26 educer.py
6 Apr 22 2001 Spanish.txt
7 Nov 30 17:37 .ssh
8 Nov 30 17:37 .ssh
8 Nov 30 17:37 .ssh
8 Nov 30 17:37 .ssh
```

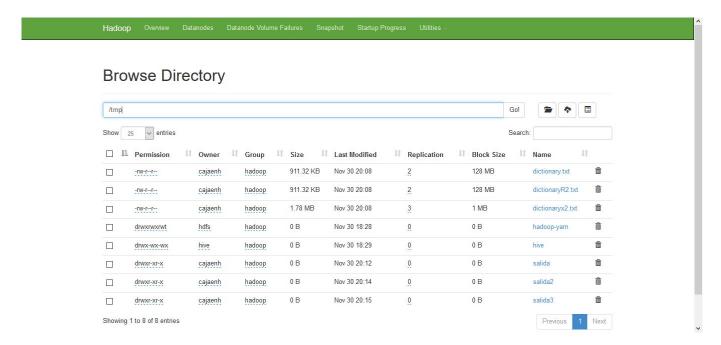
Al ejecutarse hadoop fs -ls /tmp pueden verse los ficheros de salida que se han generado en el HDFS.

En la pestaña Hadoop JobHistory pueden verse los procesos ejecutados y su estado (SUCCEEDED o FAILED):





6. En el navegador web del HDFS de nuestro clúster podemos ver su contenido: los tres diccionarios subidos, más las tres carpetas de salida con el resultado de aplicar la función Map Reduce a esos ficheros:

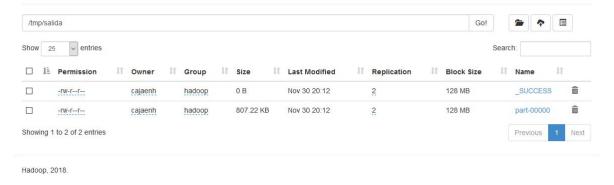


a. En la carpeta **salida** se encuentra el resultado (satisfactorio) de aplicar el Map Reduce al fichero **dictionary.txt** (se adjunta el **archivo salida part-00000.txt**):

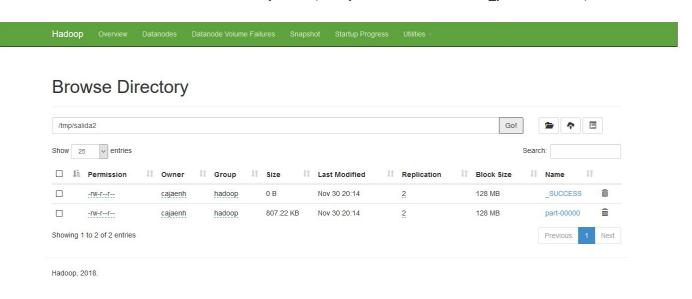


Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities

Browse Directory



b. En la carpeta **salida2** se encuentra el resultado (satisfactorio) de aplicar el Map Reduce al fichero **dictionaryR2.txt** (se adjunta el **archivo salida2_part-00000.txt**):

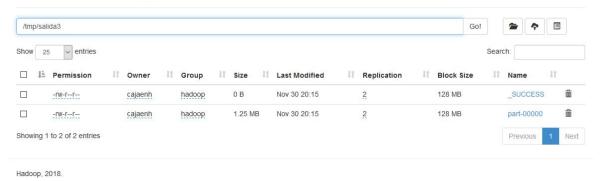


c. En la carpeta **salida3** se encuentra el resultado (satisfactorio) de aplicar el Map Reduce al fichero **dictionaryx2.txt** (se adjunta el **archivo salida3_part-00000.txt**):



Hadoop Overview Datanodes Datanode Volume Failures Snapshot Startup Progress Utilities

Browse Directory



7. Por último, para mostrar el resultado de la palabra House utilizamos el comando grep:

```
$ hadoop fs -cat /tmp/salida/part-00000 | sort | grep -i -w House
> house.txt
$ hadoop fs -cat /tmp/salida2/part-00000 | sort | grep -i -w House
> house2.txt
$ hadoop fs -cat /tmp/salida3/part-00000 | sort | grep -i -w House
> house3.txt
```

Los resultados se guardan en ficheros de texto house.txt, house2.txt y house3.txt.



Si se quiere ver el contenido de cualquiera de ellos utilizamos el comando cat:

\$ cat house.txt
\$ cat house2.txt
\$ cat house3.txt

El resultado es el siguiente (el de **house3.txt** duplicando las líneas de los otros dos):

```
butcher, slaughter-house. macellarius
casa    house[Conjunction]|casa (house)
chapter, chapter meeting, chapter house. capitulus
country house, country estate /(med.) manor, village. villa
guest house    Pension (f)
house    casa[Noun]|casa|CASA|casa[Noun]|CASITA|das Haus|Haus
(n)|la casa|maison[Noun]|Unterkunft (f)|Rente (f)
household, house, abode. domus
```



house, home, residence. domus
house wine Hauswein (m)
lady of the house Hausfrau (f)
(masc. nom. sing.) THAT (house) is filthy. ille
(masc. nom. sing.) THIS (house) is filthy. hic
(prep. + acc.) among, in the presence of, at, at the house of.
apud
wall (of a house). paries parietis